


A series of thin, black, overlapping geometric lines and polygons that create a complex, abstract pattern in the upper left portion of the slide.

DÉTECTION DES FAUX BILLETS

JULIE LORIAU SENSENBRENNER
DATA ANALYST

CONTEXTE

L'Organisation nationale de lutte contre le faux-monnayage (ONCFM) est une organisation publique ayant pour objectif de mettre en place des méthodes d'identification des contrefaçons des billets en euros.

Dans le cadre de cette lutte, nous souhaitons mettre en place un algorithme qui soit capable de différencier automatiquement les vrais des faux billets.

RESSOURCE DISPONIBLE

Une base de données historique de 1 500 billets scannés :


- 1 000 vrais billets
- 500 faux billets

Éléments distinctifs basés sur 6 mesures géométriques :

- length
- height_left
- height_right
- margin_up
- margin_low
- diagonal

ANALYSE EXPLORATOIRE & NETTOYAGE

- **Structure de l'échantillon :**
 - 1 500 lignes distribuée de la manière suivante : 2/3 de vrais billets, 1/3 de faux
 - Le déséquilibre d'origine devra être compensé dès l'entraînement du modèle
- **Analyse de la fiabilité des données :**
 - Doublons : 0
 - Valeurs manquantes : 37 valeurs → Uniquement sur la variable `margin_low`.
- **La stratégie d'intégrité :** Pour éviter tout biais de "Data Leakage", la démarche s'est faite comme suit :
 - Séparer d'abord le dataset (Train/Test)
 - Calculer l'imputation par la médiane uniquement sur le jeu d'entraînement,
 - Puis propager l'imputation sur l'ensemble du dataset






CORRÉLATIONS

Matrice de corrélation des variables (cible : is_fake)

diagonal -							
height_left -	0.02						
height_right -	-0.02	0.24					
margin_low -	-0.11	0.30	0.39				
margin_up -	-0.06	0.25	0.31	0.43			
length -	0.10	-0.32	-0.40	-0.67	-0.52		
is_fake -	-0.13	0.38	0.49	0.78	0.61	-0.85	
	diagonal	height_left	height_right	margin_low	margin_up	length	is fake -

- **length (-0,85)** : plus un billet est court, plus il est suspect
- **margin_low (+0,78)** : marge inférieure élevée → signal fort de contrefaçon



- **margin_up (+0,61)** : marge supérieure élevée, corrélation modérée
- Ces 3 variables seront les plus influentes dans le modèle

CARACTÉRISTIQUES GLOBALES

Orange : Faux billets

Bleu : Vrais billets

Observations clés

- length :


les faux billets sont systématiquement plus courts

- margin_low et margin_up :

marges plus grandes sur les contrefaçons

- height_left/right et diagonal :

moins discriminants



INDICATEURS DE PERFORMANCE

RECALL

Taux de faux billets correctement détectés
— priorité absolue de l'ONCFM

ACCURACY


Proportion globale de billets bien classés
(vrais + faux)

F1 SCORE

Moyenne harmonique Recall/Precision
Equilibre détection / fausses alertes

PRECISION

Parmi les alertes levées, proportion de
vrais faux billets



PROCESS ENVISAGÉ

- **Mis en concurrence des 4 algorithmes :**
 - Régression Logistique,
 - KNN,
 - Random Forest,
 - K-Means
- **Choix du modèle :** Retenir le modèle le plus performant vis-à-vis du risque métier (laisser passer un faux billet).
- **Industrialisation du modèle :** Livraison d'un script d'application fonctionnel, prêt à tester des fichiers de production (billets_production.csv) ou des entrées manuelles.

REGRESSION LOGISTIQUE

Métriques (jeu de test)

Accuracy : 0,99 - Recall (faux billets) : 0,97

Precision : 0,99 - AUC ROC : 0,999

Lecture de la matrice de confusion

3 faux négatifs sur 300 billets test

Risque métier : 3 faux billets non détectés


Variables clés (coefficients)

length (-0,85) - margin_low (+0,78)

margin_up (+0,61)

Modèle interprétable

Donne une probabilité de faux billet



KNN

Métriques (jeu de test)

Accuracy : 0,99 - Recall (faux billets) : 0,97

Precision : 0,99 - AUC ROC : 0,984

Paramétrage retenu

K = 5 voisins - Distance euclidienne


Lecture de la matrice de confusion

3 faux négatifs - 0 faux positif

Limite identifiée

AUC inférieure (0,984 vs 0,999)

Plus coûteux en temps si dataset grandit



RANDOM FOREST

Métriques (jeu de test)

Accuracy : 0,99 - Recall (faux billets) : 0,97

Precision : 0,99 - AUC ROC : 0,998

Paramétrage retenu

100 arbres (n_estimators) random_state=42


Lecture de la matrice de confusion

3 faux négatifs - 0 faux positif

Limite identifiée

Moins interprétable

Pipeline moins transparent pour l'ONCFM




APPRENTISSAGE NON SUPERVISÉ

Utilisation d'un modèle d'apprentissage non supervisé : le KMEANS

Recherche du Score de Silhouette :

La Silhouette atteint son maximum à K=2




Analyse de la géométrie par l'algorithme K-Means

Les billets forment deux clusters distincts par l'analyse des dimensions clés

La limite

Les deux clusters ne peuvent être reconnus directement sans analyse préalable



ROC CURVE ET AUC

Interprétation de la ROC curve

Axe X : Taux de faux positifs
(vrais billets détectés comme faux à tort)

Axe Y : Recall — faux billets détectés

Résultats AUC

Régression Logistique : 0,999

Random Forest : 0,998

KNN : 0,984

AUC proche de 1 = le modèle discrimine parfaitement vrais/faux billets à tous les seuils




TABLEAU COMPARATIF

ALGORITHME	OBJECTIF	VALEUR FALSE (RECALL)	ACCURACY	ROC CURVE AUC	AVANTAGES	INCONVENIENTS
RÉGRESSION LOGISTIQUE	Utilisée pour la classification et la probabilité d'appartenir à 0 ou 1	0,97	0,99	0,999	Simple, rapide, très lisible, donne une probabilité, bon choix quand les classes sont bien séparées	Moins adaptée si la frontière entre classes n'est pas très linéaire
KNN	Basé sur la proximité géométrique et fait un rapprochement par la majorité	0,97	0,99	0,984	Intuitif, capte bien la proximité locale, facile à comprendre	Sensible à l'échelle et plus coûteux en temps quand le dataset grossit
RANDOM FOREST	Chaque arbre va analyser une partie des données puis la forêt prendra la décision finale	0,97	0,99	0,998	Robuste, gère bien les relations non linéaires, souvent performant	Moins aisément interprétable que la régression logistique

POURQUOI RETENIR LA RÉGRESSION LOGISTIQUE ?

Performances équivalentes aux 3 modèles

Accuracy 0,99 - Recall 0,97 - AUC 0,999 (meilleure des 3)

Interprétabilité maximale

Les coefficients expliquent l'impact de chaque variable (length, margin_low...)

Probabilités de prévision

`predict_proba()` retourne $P(\text{faux billet})$ - Qualifier l'incertitude

Pipeline industrialisable

Léger, rapide, simple à réentraîner - Idéal pour la production quotidienne

ARCHITECTURE DU PIPELINE

Étape 1 — SimpleImputer (strategy=« median »)

Comble les 37 valeurs manquantes de margin_low par la médiane du train

Important : Calculé uniquement sur X_train → évite le Data Leakage

Étape 2 — StandardScaler

Centre (moyenne=0) et réduit (écart-type=1) toutes les variables

Indispensable pour la régression logistique (sensible à l'échelle)

Étape 3 — LogisticRegression

max_iter=500 - random_state=42 - Entraîné sur X_train uniquement

Sauvegarde

joblib.dump() → modele_prediction_billets.joblib

APPLICATION FONCTIONNELLE

Chargement du modèle

```
pipeline = joblib.load("modele_prediction_billets.joblib")
```

Entrée par fichier csv ou manuellement

6 colonnes : diagonal, height_left, height_right, margin_low, margin_up, length

Sorties générées

is_fake_pred : prédiction binaire (True = faux billet)

proba_faux / proba_vrai : probabilités associées à chaque billet

Avantage clé

Le pipeline intègre imputation + standardisation → pas de prétraitement manuel

```
Résultats des prédictions (Mode : csv) ---
  id  proba_faux  proba_vrai  Resultat
0  A_1      0.9988      0.0012  Faux billet
1  A_2      0.9998      0.0002  Faux billet
2  A_3      0.9997      0.0003  Faux billet
3  A_4      0.0221      0.9779  Vrai billet
4  A_5      0.0002      0.9998  Vrai billet
```

RECOMMANDATION À L'ONCFM

- Mettre en place un monitoring régulier des prédictions
- Continuer le suivi des contrefaçons
- Réentraîner le pipeline tous les 6 mois en y injectant les nouvelles contrefaçons saisies pour mettre à jour la médiane et les coefficients de régression.