

Analyse de l'évolution du profil sociodémographique

Analyse et contextualisation des profils étudiants (2022–2025)

Mise en place d'un pipeline DBT fiable, documenté et reproductible



Julie LORIAU SENSENBRENNER

DATA ANALYST

OPENCLASSROOMS



Contexte et Objectifs

Contexte du projet

Demande métier

Transformation fiable et documentée des données internes pour assurer la qualité et la conformité RGPD, avec intégration des données publiques INSEE.

Périmètre d'analyse

Étudiants inscrits au parcours Data Analyst chez OpenClassrooms.

Couverture temporelle

Données historiques de 2022 à 2025.

Objectifs de la mission

Analyse descriptive

Décrire le profil type (âge, genre, région) des étudiants Data et identifier les écarts par rapport à la population française (INSEE).

Qualité & Traçabilité

Garantir la reproductibilité des analyses via DBT et documenter le lignage des données.


Aide à la décision

Délivrer des insights actionnables et des recommandations stratégiques (féminisation, ciblage territorial).

Sources de données

OPENCLASSROOMS

Données Internes



Source

Extract des inscriptions aux parcours Data Analyst. Données nettoyées et pré-agrégées.

Variables Clés

USER_ID
YEAR_PATH_STARTED
REGION
GENDER (F/M/NC)
AGE_GROUP
NB_ETUDIANTS

Volume

Période 2022-2025

INSEE

Données Publiques



Source

Données démographiques régionales officielles.
Référentiel de population des années 2022, 2023, 2024 et 2025.

Variables Contextuelles

POPULATION_TOTALE
REGION
GENRE
TRANCHE D'AGE

Clés de Jointure

Normalisation nécessaire sur REGION (ex: DOM → DROM), AGE_GROUP et GENDER

Stack Technique & Pipeline DBT

Stack Technique





Snowflake

Data Warehouse Cloud
Région : EU-Paris AWS)
Stockage & Calcul
Visualisation



dbt Core

Transformation
Documentation automatique
Tests de qualité
Commits



Qualité des données & Nettoyage

Règles de nettoyage

Harmonisation géographique

Correction des noms de régions (ex: DOM → DROM), normalisation de la casse et des accents pour la jointure INSEE.

Standardisation des âges

Agregation des seniors en une catégorie unique "60 ans ou plus" en adéquation avec la BDD OpenClassRooms.

Gestion du Genre

Valeurs manquantes ou nulles imputées à Non Renseigné. Validation stricte des valeurs (F, M, NR).

Intégrité des données

Déduplication des enregistrements et vérification de la cohérence des clés primaires entre tables (Conditions et tests qualité).

Gouvernance & Traçabilité

Documentation DBT

Fichiers YAML complets décrivant chaque modèle, source et transformation. Génération automatique du graphe de lignage (Lineage) et du catalogue de données.

Tests automatisés

Implémentation de tests de schéma (unique, not_null) et de tests de données (accepted_values) bloquants en cas de non-conformité.

Reproductibilité

Pipeline exécutable de bout en bout, garantissant que les résultats finaux peuvent être régénérés à l'identique à partir des sources brutes.

Raw → Staging → Intermediate → Mart

Conformité RGPD & Protection des Données

Démarche stricte de mise en conformité appliquée tout au long du pipeline de traitement des données étudiantes.

Minimisation des données

Uniquement les champs nécessaires à l'analyse (âge, genre, région).

Aucune donnée identifiante (nom, email, tel) conservée.

Base Légale & Finalité

Intérêt légitime pour l'amélioration des parcours (analyse statistique interne).

Projet académique sans exploitation commerciale.

Sécurité & Chiffrement

Chiffrement des données stockées (at-rest) et en transit.
Gestion des accès par rôle (RBAC) sur Snowflake.

Souveraineté des données

Hébergement Snowflake en région **EU-Paris**, garantissant le respect des normes européennes.

Choix de l'hébergeur AWS sur Snowflake, en ce sens.

Anonymisation / Agrégation

Données agrégées par tranches d'âge, genre et région dès l'étape de staging. Suppression des valeurs uniques risquées.

Documentation & Traçabilité

Documentation des traitements dans DBT (fichiers YAML) et tenue d'un registre des traitements simplifié.

Conclusion sur les Risques

Le risque de ré-identification est considéré comme très faible.

L'absence de données directes et l'agrégation forte empêchent le croisement avec d'autres bases pour ré-identifier un individu.

Résultats - Évolution Temporelle

Volume Global d'étudiants

3 401



Étudiants analysés (2022-2025)

Répartition Annuelle

2022 990


2023 760

2024 764

2025 887


Pic d'inscriptions en 2022 puis baisse et reprise des inscriptions en 2025.

Evolution du nombre d'étudiants par année de début de formation et par genre



Résultats - Profil par âge et par cohorte (2022-2025)

Forte représentation de la catégorie 30-34 ans dans les cohortes Data.
Baisse générale de la part des 40-44 ans avec une légère reprise pour 2025.
Progression constante de la part représentée par les 20-24 ans





Résultats - Profil par Genre et par année

Part des étudiants masculins représente plus du double de la part des femmes dans la Data.

Différentiel significatif par rapport à la structure de la population nationale.

Structure relativement stable sur la période 2022-2025.


Répartition des étudiants vs population par genre



Résultats : Profil Data vs Population

Comparaison de la répartition géographique


Structure de la population française



Île-de-France

Forte sur-représentation : + 25 pts
(44 % étudiants vs 17 % population)

Etudiants en Data



Régions : Cohérence entre les étudiants et la population
→ Opportunités dans les DROM

Insights Clés des étudiants

DYNAMIQUE D'ÂGE



Cœur de cible :

25-39 ans


Potentiel présent ou à confirmer

Pic d'étudiants :

30-34 ans

Sous-représentation
marquée des > 55 ans

GENRE



Fort déséquilibre :

- Réelle sous représentation des femmes dans les formations.
- Tendance au resserrement de l'écart mais avec une marge de progression importante en vue de la féminisation.

TERRITOIRES




Île-de-France :

Représentation élevée par rapport à sa population.

Opportunités :

Départements et Régions d'Outre-Mer

COHORTES



Stabilité :

Structures d'âge et de genre comparables sur la période 2022-2025.

Pas de rupture structurelle majeure observée dans le profil des apprenants.

Recommandations Prioritaires

Stratégie d'Inclusion

Féminisation ciblée

Renforcer les messages inclusifs et développer des partenariats stratégiques (ex: associations "Femmes dans la Tech").

Jeunes 20-24 ans

Adapter l'offre avec des formats spécifiques (alternance, intensif) pour capter ce segment sous-représenté.

Croissance & Pilotage

Équilibrage territorial

Relancer l'attractivité en Île-de-France et consolider la présence dans les régions dynamiques (Normandie, Pays de la Loire).

Pilotage par la Data

Industrialiser le suivi via des dashboards automatisés sur DBT et fixer des objectifs précis par région et genre.

Limites & Perspectives

Limites méthodologiques

Données agrégées

Les données fournies (NB_ETUDIANTS=1) limitent l'analyse statistique fine. Une lecture par volumes individuels permettrait d'affiner les distributions.

Données 2025 partielles

La couverture de l'année 2025 dépend de la date d'extraction, ce qui peut nuancer l'interprétation de la reprise des inscriptions.

Biais de comparaison

Comparaison avec la population INSEE totale (incluant inactifs/retraités) au lieu de la population active.

Exclusion des 30% d'étudiants non renseignés

Perspectives d'amélioration

Nouveaux référentiels

Intégrer les données INSEE "Population Active" et "Niveau de Diplôme" pour contextualiser plus précisément les sous-représentations.

Enrichissement des données

Ajouter des variables explicatives : statut professionnel antérieur, niveau d'études initial, mode de financement.

Conclusion & Perspectives

Profil Type Observé

- ✓ Homme
- ✓ 30 – 34 ans
- ✓ Île-de-France

Feuille de Route

- ✓ Actions de **féminisation**
- ✓ Rééquilibrage territorial
- ✓ Elargissement d'âge
- ✓ Pilotage des données 2026